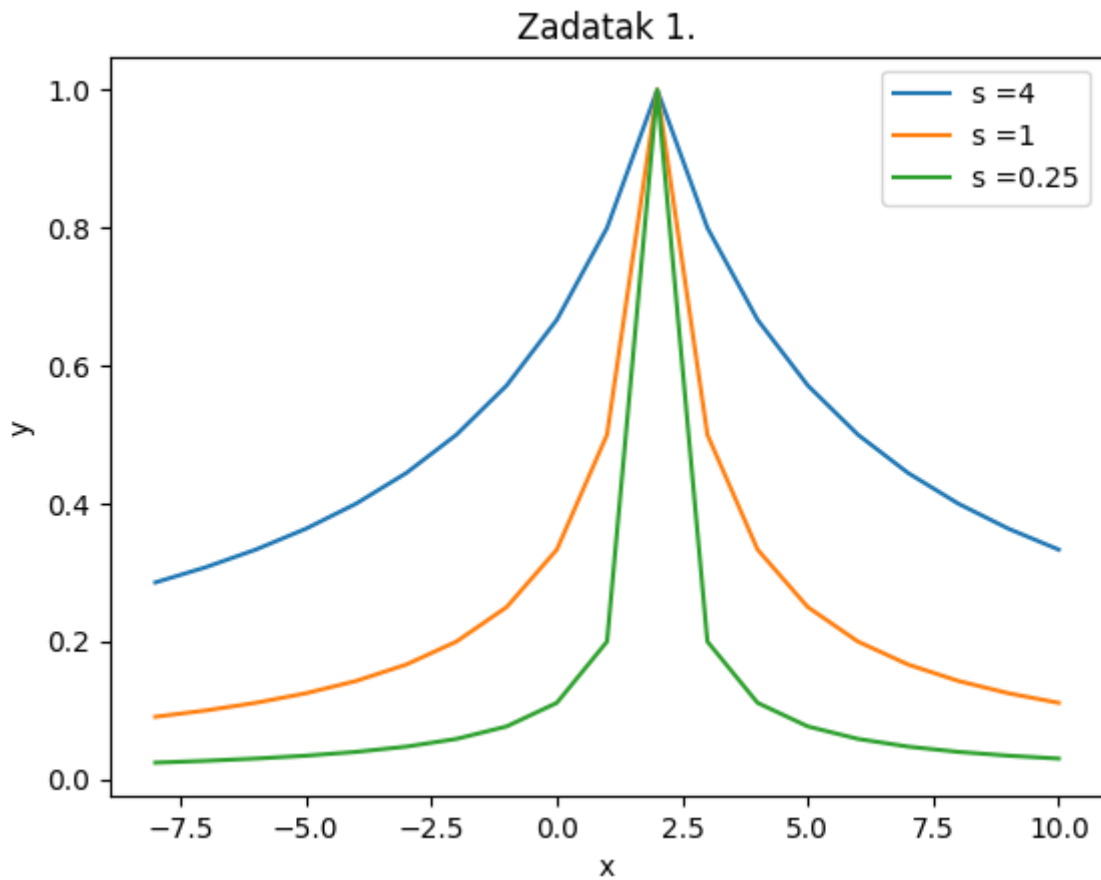



Neizrazito, evolucijsko i neuro-računarstvo

7. Domaća zadaća

1. Izlaz y neurona koji ima dva ulaza i koji se kontrolira parametrima s_1 i s_2 ovisio bi naravno o ulazu (x_1, x_2) i o parametrima (s_1, s_2). Što manji faktor s , to su sličniji izlazi za ulaze koji su blizu. Povećavanjem faktora s razlika izlaza između ulazna se povećava. U slučaju da imamo dva takva skalirajuća faktora dobili bismo istu ovu sliku samo u 2D, a sličnost izlaza ovisno o ulazima mogla bi se sa faktorima (s_1, s_2) modulirala kroz dva stupnja slobode.




2. Ulazni podaci su podijeljeni u klasterne. Svaki primjer pripada jednom klasteru a svaki klaster okuplja primjere koji pripadaju jednom od tri razreda. Klasteri su elipsoidnog oblika. Razredi nisu međusobno linearno odvojivi.




3. Svaki neuron iz prvog skrivenog sloja konačnom izvedbom genetskog algoritma trebao bi postati reprezentantom jednog klastera. Težine bih stoga inicijalno postavio tako da svaki neuron iz prvog skrivenog sloja preslika svaki od ulaznih primjera koji pripadaju istom klasteru u jednu točku koja bi mogla postati reprezentantom tog klastera, točku koja je jednako slična svim ulaznim primjerima koji pripadaju istom klasteru. Prilikom određivanja početnih težina izlaznog sloja nastojao bih staviti veće težine prema onim neuronima iz prethodnog sloja koji su reprezentanti klastera koji svi pripadaju istom razredu; razredu koji taj neuron iz izlaznog sloja predstavlja.


Kao primjer stavio sam parametre mreže trenirane genetskim algoritmom. Mogao sam i sam napisati parametre koji bi podržavali gore navedenu logiku, no obzirom da konačan rezultat također podržava navedenu logiku, stavio sam parametre mreže dobivene na kraju evolucijskog procesa.




4. Svaki neuron iz prvog skrivenog sloja konačnom izvedbom genetskog algoritma trebao bi postati reprezentantom jednog klastera, a to je na ovoj slici i prikazano. Oznake 1, 2, 3 ... , 8 predstavljaju oznaku neurona koji je „zadužen“ za određeni klaster.



Skale su različite za x i y komponentu. Skale x komponente uglavnom su oko -0.1 i 0.1, a skale y komponente oko -0.2 i 0.2. Iz slike u zadatku 2 vidljivo je da je varijanca y komponente svakog klastera veća od x varijance, stoga ćemo morati koristiti veću skalu za y komponentu kako bismo u potpunosti naučili preslikavati podatke iz dataseta.



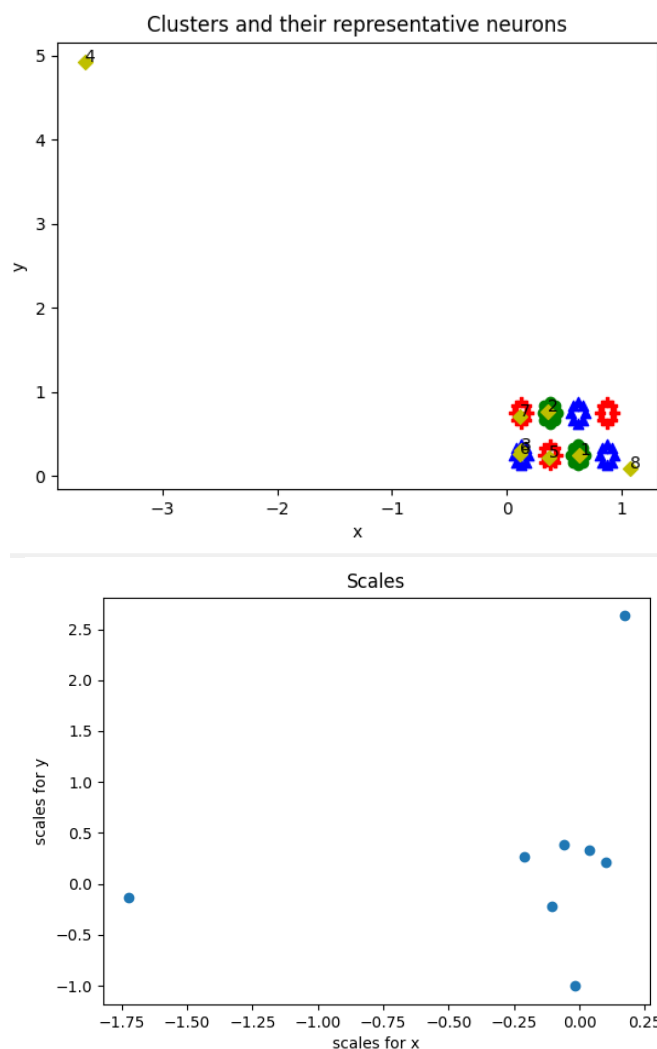


Težina w_2 svakog neurona iznosi ili 0.2 ___ ili 0.7 ___, upravo zato jer su središta klastera upravo tamo (ako gledamo y komponentu). Što se tiče težine w_1 , one su ili 0.1 ___ ili 0.3 ___ ili 0.6 ___ ili 0.8 ___ zato jer se središta klastera nalaze tamo (ako gledamo x komponentu).

Neuroni 2, 6, i 7 iz prvog (i jedinog) skrivenog sloja specijalizirali su se za klaster koji pripadaju istom razredu, a pošto je neuron 1 iz izlaznog sloja zadužen za klasifikaciju primjera u taj razred, veza iz neurona 2, 6 i 7 (skriveni sloj) prema neuronu 1 (izlazni sloj) je jaka, to jest težine su velike. Isto tako, težine ostalih neurona (1, 3, 4, 5 i 8) prema neuronu 1 su negativne što znači da ti neuroni nisu zaduženi za podražavanje neurona 1 koji predstavlja neki njima nepoznat razred.

Ista logika vrijedi i za druge neurone i njima pripadne težine.

5. Trajanje postupka učenja mreže 2 x 8 x 3 je 1082.955284833908 sekundi.
Trajanje postupka učenja mreže 2 x 8 x 4 x 3 je 1485.722993850708 sekundi.
Postupak učenja traje više u slučaju složenije mreže čisto zato jer ima više parametara koje treba optimizirati. Mreža je naučila pravilno klasificirati sve ulazne primjere.



Ne vidim nekakav pretjerani smisao u položaju koji su poprimili neuroni tipa 1. Njihovi skalirajući faktori također mi nemaju smisla.

6. Uspio sam dobiti točnu klasifikaciju svih primjera. Parametri za neurone tipa 1 najboljeg rješenja prikazani su na slici. Izgubili smo to da svaki neuron postane reprezentant jednog klastera. Neurona nema dovoljno mnogo. Bez obzira na to mreža uspijeva s ostalim neuronima nadoknaditi izgubljeno te ispravno klasificirati svaki ulazni primjer.

